

정규표현식(Regular Expression) 상세 분석 리포트

데이터 전처리 및 텍스트 마이닝의 필수 도구 가이드

1. 정의 및 개념 설명

정규표현식(Regex)은 특정한 규칙을 가진 문자열의 집합을 표현하는 데 사용하는 형식 언어입니다. 프로그래밍 언어에 국한되지 않고 데이터 분석, 텍스트 편집기, 서버 로그 분석 등 다양한 분야에서 활용됩니다. 특히 데이터 전처리 단계에서 불필요한 특수문자 제거, 데이터 정제, 패턴 기반 치환 등을 수행할 때 없어서는 안 될 필수적인 도구입니다.

2. 정규표현식 핵심 문법 및 중요도

기호	의미	예시	중요도
.	임의의 한 문자	a.b (acb, a1b 등과 매치)	☆
* / +	0회 이상 / 1회 이상 반복	ab*, ab+	★★
?	0회 또는 1회 존재 (Optional)	ab?	★★★★☆
^ / \$	문자열의 시작 / 끝 표시	^abc, abc\$	☆
[]	문자 집합 및 범위 지정	[a-z], [0-9], [가-힣]	★★★
\d / \s	숫자 / 공백 문자	\d+ (연속된 숫자)	★★
	OR (둘 중 하나 선택)	`apple` orange`	

3. Python 실전 활용: 데이터 치환 및 정제 (re.sub)

함수: `re.sub(pattern, repl, string)` (중요도: ★★★★★)

설명: 문자열 내에서 정규표현식 패턴과 일치하는 부분을 찾아 다른 문자열(`repl`)로 치환합니다. 데이터 전처리 시 노이즈 제거에 가장 많이 사용됩니다.

- 특수문자 제거:** 한글, 영문, 숫자만 남기고 나머지 기호 삭제
- 데이터 정규화:** 날짜 형식의 일치화나 전화번호의 구분 기호 제거
- 불용어 처리:** 분석에 불필요한 단어를 일괄적으로 제거하거나 공백으로 대체

[실전 코드 예시]

```
import re

# 원본 텍스트: 특수문자와 노이즈 포함
text = "안녕하세요! Hello World... 1234 #특수문자_데이터"
```

```
# 한글과 공백만 남기고 모든 문자 제거 패턴
# [^ ]는 '제외'를 의미하며, 가-힐은 한글 전체 범위를 의미함
clean_text = re.sub('[^가-힐 ]', '', text)

print(f"정제 전: {text}")
print(f"정제 후: {clean_text}")
# 결과: 안녕하세요 특수문자데이터
```

4. 주요 파싱 함수 및 사용 팁

1. **re.findall()**: 패턴과 일치하는 모든 문자열을 찾아 리스트로 반환합니다. (추출 시 유용)
2. **re.search()**: 문자열 전체를 스캔하여 첫 번째로 일치하는 항목을 반환합니다.
3. **Raw String (r")**: 정규표현식 내의 백슬래시(\) 처리를 위해 패턴 문자열 앞에 **r** 을 붙이는 것을 권장합니다 (예: `r'\d+'`).
4. **re.compile()**: 동일한 패턴을 여러 번 반복해서 사용할 경우, 패턴을 미리 컴파일하여 속도를 향상시킬 수 있습니다.

본 리포트는 정규표현식의 기초부터 실무 활용까지의 핵심 내용을 담고 있습니다.